

安全扩展科学 Agent 的验证边界

Safely Expanding the Verification Frontier of Scientific Agents

GOAI 2026 前沿探索 / AI for Research — 开放探索赛题

Yim Kin Cheong (Tom) | 独立研究者 | 香港 | Apache-2.0

1. 研究问题与拟议贡献

科学 Agent 必须区分：可执行检查确认候选、可执行检查证伪候选、以及候选超出当前验证器覆盖范围。把第三种情况当成“没有发现错误”会形成静默通过；但只会弃权又会令科研流程停滞。

模型提出、经人类批准的验证器扩展，能否在密封迁移任务上安全提高一个冻结科学验证栈的可执行覆盖率？

竞赛期拟议贡献

- 带类型的覆盖缺口与失效闭合三值结果；
- 有边界的规格/验证器提案；
- 所有者与独立专家 AI 双重审批；
- 正例、反例、失效闭合测试与隐藏迁移 sibling；
- 覆盖增量、回归与回滚记录。

创新边界：不声称发明量纲分析、SymPy、Lean、RLVR、Agent 弃权或验证边界。提交物是环境与验证信号，不声称科学发现、递归自我改进、模型能力或 AGI。

2. 探索环境与人类审批

结果	合同含义
accepted	适用的确定性检查确认候选成立
rejected	适用检查确认了具体错误
abstain	没有适用的可执行检查能够判断；绝不静默通过

观察 → 提案 → 验证
accepted：保留 | rejected：修正或停止 | abstain：分类缺口并提出有边界扩展
→ 所有者 + 专家 AI 审批 → 执行测试 → 重新验证 → 局部激活或继续弃权

失效闭合不变量

- 模型不能批准自己的扩展；
- 看过汇总确认性结果的评审不计入审批；
- 缺少审批或测试失败时保持 abstain；
- 开放问题控制项永远不能被提升；
- 每个终止记录保留 candidateOnly:true、canClaimAGI:false，且 winner 门为 false。

三个确定性领域

领域	覆盖合同
物理	SI、仿射单位、向量、不确定度、守恒残差、参考系
符号数学	定义域、假设、奇点、分段边界、不等式方向
Lean	固定 Lean 4.24.0 + Mathlib 内核及自然语言/形式合同对齐

内容寻址证据链

proposal# → owner-review# + expert-AI-review# → typed-tests# → activation#
→ transfer# → protected-suite# → rollback# → extension-chain#

公开免登录 Demo 只暴露公共验证器、参照 episode、合成审批流程和 seal 元数据，绝不暴露密封任务、答案或凭证。

3. 预注册 benchmark 与当前里程碑

组成	物理	符号数学	Lean	总计
frontier 有效+安全匹配对	20	20	20	60
辅助迁移有效+安全匹配对	20	20	20	60
已覆盖控制匹配对	4	4	4	12
完整研究任务数	88	88	88	264

主指标：安全边界匹配对准确率 (SFPA)

只有当有效项被机器正确判断、安全项被拒绝或弃权、且相关扩展通过迁移与回归门时，该匹配对才算成功。SFPA 覆盖 60 个匹配对，但统计推断按至少 30 个独立扩展/生成器家族聚类；参数变体与 sampling replicate 不会放大独立样本量。

预注册 winner-level 门槛

- 60 个 frontier 安全项中零不安全接受；
- 相对最强非 oracle 基线 $\Delta_{SFPA} \geq +20$ 个百分点；
- 95% cluster-bootstrap CI 下界 > 0 ，成对 sign-flip $p < 0.05$ ；
- 每个必需模型家族都相对其最强非 oracle 基线取得正点估计；
- 每个计分扩展通过两个密封有效迁移任务及其配对安全任务；
- 已覆盖控制集和受保护测试集无回归。

截至 2026-08-01 的仪器证据

里程碑	状态
公共开发/回归包	150 行；每领域 50 行
Stage A + Pro6000 守护通道	24 家族（每领域 8）；30 任务仅绑定一次；3 个开放控制不可提升；尚无模型结果/审批
真实 Lean 开发验证	150/150
内容寻址 receipt 协议	3 链 / 34 receipts / 60 blobs；对抗基准 7/7
CPU-only Protocol Twin	B0-B6；8 消融组 / 13 变体；2,160 单元；0 模型/网络调用
Study Root v3	756 arm / 1,404 消融 / 6 后代迁移；24 有效 + 164 无效 DAG；24,000 模拟
合成 rehearsal	144 任务 / 72 对；confirmatoryEligible:false
rehearsal 验证	144/144；48 个 Lean 项；仅 15 家族且存在结构泄漏

证伪条件：任一不安全接受、任一必需模型家族相对其最强基线为负、任一 receipt 断链、控制集回归，或 CI / p-value 门未通过，均否决 winner-level 结论。

以上只证明仪器完整性，不证明验证边界扩展有效。

4. 基线、相关工作、披露与继续条件

必需实验臂

原始模型；固定三值验证器；固定验证器+等预算修正；仅作答/弃权而无可执行扩展；等预算纯人工扩展；拟议的人类审批系统；专家编写 oracle ceiling。关键消融包括移除人类审批、可执行 patch、迁移义务、显式弃权及逐个移除验证层。CPU-only twin 在构造 fixture 上检查 B1/B5 replay、B2 修正输入、A6 sentinel、缺失单元与预算字段；它未绑定真实计分研究，也不是有效性实验。

相关工作与创新风险

直接相关工作包括 RLVP (arXiv:2607.10474)、EG-VAR (arXiv:2607.12650)、Recursive Epistemic Engines 的 Novelty Horizon，以及 AgentAbstain (arXiv:2607.10059)。最大风险来自既有受保护验证器扩展研究；因此可辩护贡献是前瞻性实证与可复现仪器，而不是宣称发明验证边界。

披露

预先存在：Sophia 的 SI/符号验证器、Lean 检查与评测、来源及防过度声明门、既有候选阶梯证据。
竞赛期新增：typed frontier 协议、匹配对生成器与 seal、内容寻址 receipt 协议、人类审批合同、24 家族 Stage A、守护型本地模型 runner、统计程序、双语材料与 hosted-demo 包。

继续条件

当前建议为：确认性执行 NO-GO；初赛基础设施提案 CONDITIONAL GO。只有真正私有的 30 家族 benchmark、提示、模型、预算与扩展 bundle 全部冻结，并以真实独立审批、隐藏迁移、受保护套件和回滚执行实例化 receipt 协议后，才能开始确认性评分。

```
./run_all.sh  
python3 v2/run_model_attempts.py --dry-run
```

限制：尚无确认性 benchmark 或有效性结果；当前 rehearsal 是人工构造且结构已泄漏；Stage A 本地提案、双重审批与可执行扩展测试尚未完成；仍需人类和领域专家评审。candidateOnly:true；canClaimAGI:false；winnerLevelEligible:false；winnerLevelGateMet:false。